UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
DIRETORIA DE PESQUISA E PÓS GRADUAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

JÔNATAS TRABUCO BELOTTI

IMPLEMENTAÇÃO REDE NEURAL PERCEPTRON

RELATÓRIO

PONTA GROSSA
2017

JÔNATAS TRABUCO BELOTTI

IMPLEMENTAÇÃO REDE NEURAL PERCEPTRON

Relatório apresentado como requisito parcial à obtenção de nota na disciplina de Fundamentos de Redes Neurais Artificiais do Programa de Pós-Graduação em Engenharia Elétrica, da Universidade Tecnológica Federal do Paraná– Campus Ponta Grossa.

Professor: Prof. Dr. Sérgio Okida

PONTA GROSSA
2017

SUMÁRIO

1 INTRODUÇÃO

A rede neural mais simples conhecida é a *Perceptron*, idealizada por Rosenblatt (1958), seu proposito era implementar um modelo computacional baseado no funcionamento da retina (da Silva; SPATTI; FLAUZINO, 2010).

O *Perceptron* é constituído por apenas 1 neurônio artificial que recebe todos os sinais de entrada e devolve uma única saída. A Imagem 1 ilustra a arquitetura de uma rede *Perceptron*.

Figura 1 – Rede *Perceptron*

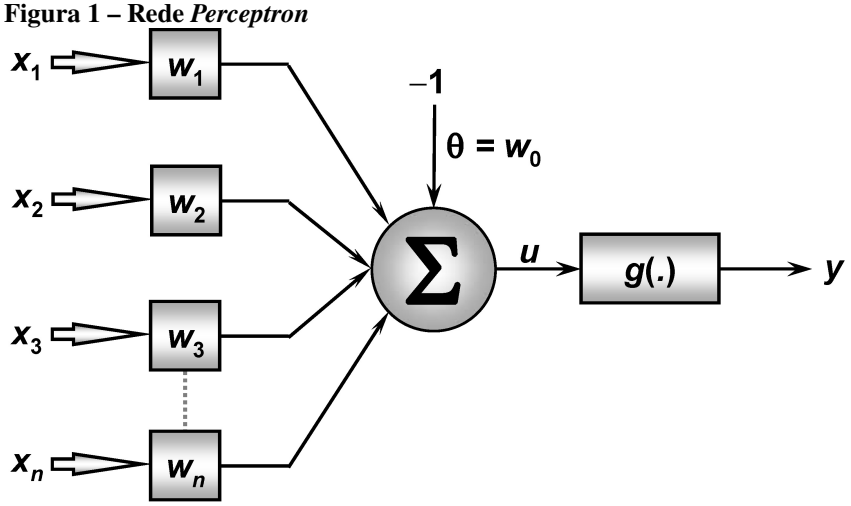

Fonte: da Silva, Spatti e Flauzino (2010).

Na Figura 1 é possível ver os sinais de entrada $\{x_1, x_2, x_3, \ldots, x_n\}$, os pesos sinápticos $\{w_0, w_1, w_2, w_3, \ldots, w_n\}$ sendo que o peso sináptico w_0 é referente ao limiar de ativação (θ), o limiar de ativação denotado por θ, o combinador linear denotado por $\sum$, o potêncial de ativação denotado por u, a função de ativação $g(.)$ e por fim o sinal de saída da rede y.

Este relatório tem como objetivo descrever o desenvolvimento do projeto prático 3.6 do livro Redes neurais artificias para engenharia e ciências aplicadas de da Silva, Spatti e Flauzino (2010), o projeto consiste na implementação, treinamento e teste de uma rede neural do tipo *Perceptron* para a classificação de amostras de óleo.

1.1 ESTUDO DE CASO

O projeto prático 3.6 do livro Redes neurais artificias para engenharia e ciências aplicadas de da Silva, Spatti e Flauzino (2010), propões o desenvolvimento de uma rede neural Perceptron para a classificação de amostras de óleo. As amostras de óleo podem ser classificadas em duas classes de pureza $\{P_1$ e $P_2\}$, essa classificação se da pela medição de três propriedades físico-químicas do óleo representadas por $\{x_1, x_2$ e $x_3\}$.

O livro trás o conjunto de treinamento da rede, aqui apresentado no Anexo A, e define

o valor -1 para óleo pertencente a classe P_1 e o valor 1 para óleo pertencente a classe P_2.

Também é descrita a arquitetura que a rede deve ter, possuindo três sinais de entrada $\{x_1, x_2$ e $x_3\}$ com seus respectivos pesos sinápticos $\{w_1, w_2$ e $w_3\}$, sendo os sinais de entrada referentes as três propriedades físico-químicas do óleo. Além disso a rede deve possuir um limiar de ativação θ de valor -1 com um peso sináptico w_0 associado a ele, um combinador linear $\sum$, o potencial de ativação u, uma função de ativação $g(.)$ e por fim um sinal de saída y que pode assumir os valores de 1 ou -1. A Figura 2 mostra detalhadamente a arquitetura que a rede deve ter.

Figura 2 – Arquitetura proposta rede *Perceptron*

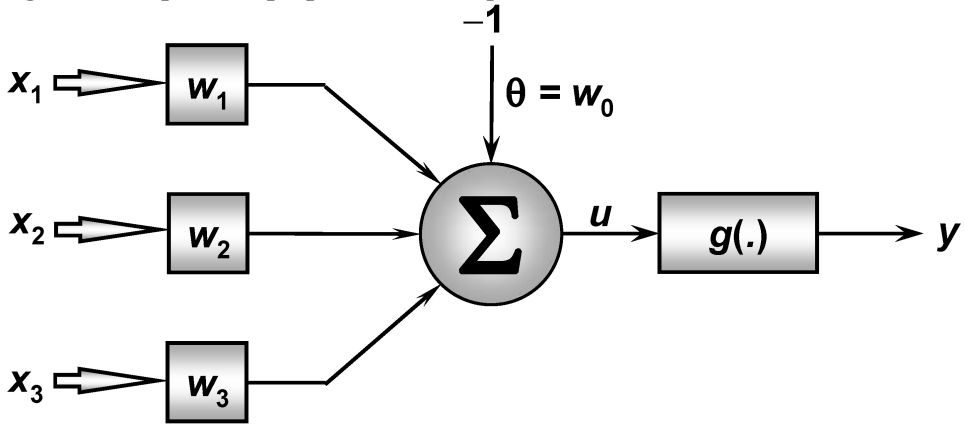

Fonte: da Silva, Spatti e Flauzino (2010).

Para o treinamento da rede é especificado a utilização do algoritmo supervisionado de *Hebb* para a classificação de padrões com uma taxa de aprendizagem de $0,01$.

2 DESENVOLVIMENTO ESTUDO DE CASO

Esse capítulo apresenta o desenvolvimento do estudo de caso proposto na Seção 1.1, apresentando a implementação da rede na Seção 2.1, o treinamento na Seção 2.2, a execução da rede na Seção 2.3 e a discussão dos resultados obtidos na Seção 2.4.

2.1 IMPLEMENTAÇÃO E TESTE

A rede neural Perceptron foi implementada na linguagem Java, visando facilitar o acesso ao código fonte o mesmo, juntamente com um arquivo contendo o conjunto de dados de treinamento foram disponibilizados em um repositório do *GitHub* que pode ser acessado pelo link <https://github.com/jonatastbelotti/RedePerceptron>.

A rede neural foi implementada através da classe *Perceptron*, que é apresentada no Apêndice A. As Seções 2.1.1, 2.1.2, 2.1.3 e 2.1.4 trazem a explicação detalhada dos principais métodos da classe.

2.1.1 Inicialização dos pesos sinápticos

Incialmente os pesos sinápticos da rede são números aleatórios gerados entre 0 e 1, no Código 1 nota-se, entre as linhas 14 e 17, que o construtor vazio da classe *Perceptron* inicia o valor dos pesos sinápticos através do método *random.nextDouble()*, método esse que gera números aleatórios entre 0 e 1.

Código 1 – Construtor da classe Perceptron

```
1  public class Perceptron {
2    private final double PASSO_APRENDIZAGEM = 0.01;
3
4    private double peso0;
5    private double peso1;
6    private double peso2;
7    private double peso3;
8    private double ultimaResposta;
9    private int numEpocasTreinamento;
10
11   public Perceptron() {
12     Random random = new Random();
```

```
14      this.peso0 = random.nextDouble();
        this.peso1 = random.nextDouble();
16      this.peso2 = random.nextDouble();
        this.peso3 = random.nextDouble();
18      this.ultimaResposta = 0.0;
        this.numEpocasTreinamento = 0;
20    }
```

2.1.2 Ajuste dos pesos sinápticos

O processo de treinamento é implementado na classe *Perceptron* pelo método treinarRede, que recebe como parâmetro o arquivo contendo os dados de treinamento e através do algoritmo supervisionado de Hebb atualiza os pesos sinápticos a cada iteração até que não haja mais erro de classificação. O Código 2 apresenta a implementação em Java do método treinarRede.

Analisando o código, podemos verificar que o laço que compreende as linhas 18 à 65 realiza várias épocas de treinamento enquanto houver erro de classificação. As linhas 22 a 40 são responsáveis por lerem cada linha do arquivo com os dados de treinamento e retirarem os respectivos sinais de entrada e a saída esperada. Na linha 43 é realizado o cálculo que gera o potencial de ativação. Nessa mesma linha o potencial de ativação já é inserido na função de ativação gerando assim a saída da rede.

Na linha 45 a saída da rede é comparada com a saída esperada para essa entrada, se os valores forem iguais nada é feito, entretanto se os valores forem diferentes, nas linhas 46 a 49 os pesos sinápticos são ajustados.

Código 2 – Método treinarRede classe Perceptron

```
1  public boolean treinarRede(ArquivoDadosTreinamento
       arquivoTreinamento) {
2       FileReader arq;
        BufferedReader lerArq;
4       String linha;
        String[] vetor;
6       int i;
        int acertou;
8       int maiorAcerto = 0;
        boolean erro = true;
10      double entrada1;
        double entrada2;
12      double entrada3;
```

```
    double saidaEsperada;
14
    this.numEpocasTreinamento = 0;
16
    try {
18    while (erro) {
        this.numEpocasTreinamento++;
20      acertou = 0;
        erro = false;
22      arq = new FileReader(arquivoTreinamento.getCaminhoCompleto
           ());
        lerArq = new BufferedReader(arq);
24
        linha = lerArq.readLine();
26      if (linha.contains("x1")) {
          linha = lerArq.readLine();
28      }

30      while (linha != null) {
          vetor = linha.split("\\s+");
32        i = 0;

34        if (vetor[0].equals("")) {
            i = 1;
36        }

38        entrada1 = Double.parseDouble(vetor[i++].replace(",", "."
             ));
          entrada2 = Double.parseDouble(vetor[i++].replace(",", "."
             ));
40        entrada3 = Double.parseDouble(vetor[i++].replace(",", "."
             ));
          saidaEsperada = Double.parseDouble(vetor[i].replace(",",
             "."));
42
          this.ultimaResposta = funcaoDegrauBipolar((entrada1 *
             this.peso1) + (entrada2 * this.peso2) + (entrada3 *
             this.peso3) + (-1.0 * this.peso0));
44
          if (this.ultimaResposta != saidaEsperada) {
46          peso0 = peso0 + (PASSO_APRENDIZAGEM * (saidaEsperada -
               this.ultimaResposta) * -1.0);
```

```
            peso1 = peso1 + (PASSO_APRENDIZAGEM * (saidaEsperada -
               this.ultimaResposta) * entrada1);
48          peso2 = peso2 + (PASSO_APRENDIZAGEM * (saidaEsperada -
               this.ultimaResposta) * entrada2);
            peso3 = peso3 + (PASSO_APRENDIZAGEM * (saidaEsperada -
               this.ultimaResposta) * entrada3);
50          erro = true;
          } else {
52          acertou++;
          }
54
          linha = lerArq.readLine();
56      }

58      arq.close();

60      if (acertou > maiorAcerto) {
          maiorAcerto = acertou;
62        Comunicador.addLog("Epoca " + this.numEpocasTreinamento +
              " acertou " + acertou + " ("+peso0+"; "+peso1+"; "+
             peso2+"; "+peso3+")");
        }
64
    }
66
    Comunicador.addLog("Fim do treinamento.");
68  } catch (FileNotFoundException ex) {
    return false;
70  } catch (IOException ex) {
    return false;
72  }

74  return true;
}
```

2.1.3 Função degrau bipolar

Como foi definido na Seção 1.1, a saída da rede deve ser -1 para óleo pertencente a classe P_1 e 1 para óleo pertencente a classe P_2, dessa forma a função de ativação utilizada foi a função degrau bipartido, que segue o funcionamento:

$$f(x) = \begin{cases} -1 & \text{se} \quad x < 0, \\ 0 & \text{se} \quad x = 0, \\ 1 & \text{em} \quad x > 0 \end{cases}$$

Na implementação em Java da rede *Perceptron* a função de ativação do tipo degrau bipartido foi implementada pelo método funcaoDegrauBipolar que pode ser visto no Código 3.

Código 3 – Método funcaoDegrauBipolar da classe Perceptron

```
1  private double funcaoDegrauBipolar(double valor) {
2      if (valor == 0.0) {
         return 0.0;
4      }

6      if (valor < 0.0) {
         return -1.0;
8      }

10     if (valor > 0.0) {
         return 1.0;
12     }

14     return 0.0;
   }
```

Perceba que este método foi invocado na linha 43 do Códgo 2.

2.1.4 Generalização

A etapa de generalização da rede foi implementada através do método classificar, que é apresentado no Código 4. Nele verifica-se que a linha 6 é responsável por gerar o potencial de ativação e aplica-lo a função de ativação, gerando assim a saída da rede. Por fim nas linhas 8 a 13 a saída da rede é verificada para imprimir a classificação correspondente.

Código 4 – Método classificar da classe Perceptron

```
1  public String classificar(double valor1, double valor2, double
       valor3) {
2      String resposta;

4      resposta = "";
```

```
6       this.ultimaResposta = funcaoDegrauBipolar((valor1 * this.peso1)
            + (valor2 * this.peso2) + (valor3 * this.peso3) + (-1.0 *
           this.peso0));

8       if (this.ultimaResposta == -1.0) {
          resposta = "Classe P1";
10      }
        if (this.ultimaResposta == 1.0) {
12        resposta = "Classe P2";
        }
14

        return resposta;
16    }
```

2.2 TREINAMENTO

Com a finalidade de testar a rede neural desenvolvida a mesma foi treinada 5 vezes com o conjunto de treinamento contido no Anexo Anexo A. Em cada treinamento o número de épocas necessárias para treinar a rede foi anotado, assim como o vetor contendo os pesos sinápticos inicias e finais. O resultado dos 5 treinamentos podem ser visto nos dados da Tabela 1.

Analisando a Tabela 1 é possível verificar que a média do número de épocas necessárias para treinar a rede é de aproximadamente 400 épocas.

2.3 EXECUÇÃO

Para cada um dos 5 treinamentos descritos na Seção 2.2 a rede *Perceptron* foi testada na classificação das amostras de óleo para que os resultados obtidos em cada treinamento pudessem ser comparados. Os resultados obtidos na classificação mediante cada treinamento pode ser visto na Tabela 2.

Note que para a mesma amostra de óleo todos os treinamentos apresentaram a mesma classificação, não havendo divergência entre os resultados.

Tabela 1 – Resultados do treinamento da rede

Treinamento	Vetor de pesos iniciais				Vetor de pesos finais				Nº épocas
	$\mathbf{w_0}$	$\mathbf{w_1}$	$\mathbf{w_2}$	$\mathbf{w_3}$	$\mathbf{w_0}$	$\mathbf{w_1}$	$\mathbf{w_2}$	$\mathbf{w_3}$	
T(1)	0.546383366	0.914173290	0.4531600950	0.831476594	−2.91361663	1.426099290	2.402110095	−0.678903405	351
T(2)	0.805904511	0.2463353299	0.56257503	0.2327497693	−3.014095488	1.463087329	2.443543031	−0.720236230	391
T(3)	0.896602871	0.808698103	0.4878806631	0.2303045852	−3.083397128	1.56789210	2.483794663	−0.735089414	428
T(4)	0.3882159565	0.626372812	0.1246781379	0.1962799425	−3.13178404	1.6000948	2.514918137	−0.745256057	421
T(5)	0.600485862	0.52229995	0.485077395	0.953812771	−3.05951413	1.55214595	2.468979395	−0.730609228	408

Fonte: Autoria própria.

Tabela 2 – Amostras de óleo para validar a rede *Perceptron*

Amostra	x_1	x_2	x_3	y T(1)	y T(2)	y T(3)	y T(4)	y T(5)
1	$-0,3665$	$0,0620$	$5,9891$	P_1	P_1	P_1	P_1	P_1
2	$-0,7842$	$1,1267$	$5,5912$	P_2	P_2	P_2	P_2	P_2
3	$0,3012$	$0,5611$	$5,8234$	P_2	P_2	P_2	P_2	P_2
4	$0,7757$	$1,0648$	$8,0677$	P_2	P_2	P_2	P_2	P_2
5	$0,1570$	$0,8028$	$6,3040$	P_2	P_2	P_2	P_2	P_2
6	$-0,7014$	$1,0316$	$3,6005$	P_2	P_2	P_2	P_2	P_2
7	$0,3748$	$0,1536$	$6,1537$	P_1	P_1	P_1	P_1	P_1
8	$-0,6920$	$0,9004$	$4,4058$	P_2	P_2	P_2	P_2	P_2
9	$-1,3970$	$0,7141$	$4,9263$	P_1	P_1	P_1	P_1	P_1
10	$-1,8842$	$-0,2805$	$1,2548$	P_1	P_1	P_1	P_1	P_1

Fonte: Autoria própria.

2.4 DISCUSSÕES

Observando a Tabela 1 na Seção 2.2 nota-se que o número de épocas necessárias para treinar a rede foi diferente em cada um dos 5 treinamentos realizados. Isso ocorre devido aos pesos sinápticos iniciais terem sido gerados de forma aleatória, de forma que quanto mais próximos os pesos estiverem dos valores ótimos mais rápido será o treinamento da rede.

Uma das características da rede *Perceptron* é que ela aplica apenas filtros lineares, logo sua utilização deve deve priorizar conjuntos com classes linearmente separáveis. A rede *Perceptron* desenvolvida nesse trabalho foi capaz de mapear o conjunto de dados utilizado no treinamento de forma que uma mesma entrada não teve duas classificações diferentes em todas as vezes que a rede foi testada, como a rede *Perceptron* funciona corretamente apenas para classificações linearmente separáveis pode-se dizer que o conjunto de dados utilizado nesse trabalho é linearmente separável, visto que se isso não fosse verdade em pelo menos 1 teste uma mesma entrada apresentaria duas classificações diferentes.

3 CONCLUSÃO

A rede *Perceptron*, apesar de ser o modelo mais simples de rede neural se mostrou capaz de resolver o problema da classificação de óleo. No que diz respeito aos treinamentos realizados a rede apresentou um número médio de 400 épocas para a realização do treinamento. A limitação da rede *Perceptron* em classificar apenas dados linearmente separáveis não foi um problema para este trabalho, como o conjunto de dados tratado aqui é linearmente separável a rede realizou classificações corretas em todos os teste realizados.

REFERÊNCIAS

da Silva, Ivan Nunes; SPATTI, Danilo Hernane; FLAUZINO, Rogério Andrade. **Redes Neurais Artificiais Para Engenharia e Cincias Aplicadas - Curso Pratico**. 1. ed. São Paulo: ARTLIBER, 2010. ISBN 978-85-88098-53-4.

ROSENBLATT, Frank. The perceptron: A probabilistic model for information storage and organization in the brain. **Psychological review**, American Psychological Association, v. 65, n. 6, p. 386, 1958.

APÊNDICE A - IMPLEMENTAÇÃO DA CLASSE *PERCEPTRON*

```
1  package Model;
2
   import View.Comunicador;
4  import java.io.BufferedReader;
   import java.io.FileNotFoundException;
6  import java.io.FileReader;
   import java.io.IOException;
8  import java.util.Random;

10 /**
    *
12  * @author Jonatas Trabuco Belotti [jonatas.t.belotti@hotmail.com]
    */
14 public class Perceptron {

16   private final double PASSO_APRENDIZAGEM = 0.01;

18   private double peso0;
     private double peso1;
20   private double peso2;
     private double peso3;
22   private double ultimaResposta;
     private int numEpocasTreinamento;
24
     public Perceptron() {
26     Random random = new Random();

28     this.peso0 = random.nextDouble();
       this.peso1 = random.nextDouble();
30     this.peso2 = random.nextDouble();
       this.peso3 = random.nextDouble();
32     this.ultimaResposta = 0.0;
       this.numEpocasTreinamento = 0;
34   }

36   public Perceptron(double peso0, double peso1,
      double peso2, double peso3) {
```

```
38      this.peso0 = peso0;
        this.peso1 = peso1;
40      this.peso2 = peso2;
        this.peso3 = peso3;
42      this.ultimaResposta = 0.0;
        this.numEpocasTreinamento = 0;
44    }

46    public double getUltimaResposta() {
        return ultimaResposta;
48    }

50    public int getNumEpocasTreinamento() {
        return numEpocasTreinamento;
52    }

54    public double getPeso0() {
        return peso0;
56    }

58    public double getPeso1() {
        return peso1;
60    }

62    public double getPeso2() {
        return peso2;
64    }

66    public double getPeso3() {
        return peso3;
68    }

70    public boolean treinarRede(ArquivoDadosTreinamento
       arquivoTreinamento) {
72      FileReader arq;
        BufferedReader lerArq;
74      String linha;
        String[] vetor;
76      int i;
```

```
        int acertou;
78      int maiorAcerto = 0;
        boolean erro = true;
80      double entrada1;
        double entrada2;
82      double entrada3;
        double saidaEsperada;
84
        Comunicador.iniciarLog("Inicio treinamento (" + peso0
86            + "; " + peso1 + "; " + peso2 + "; " + peso3 + ")");
        this.numEpocasTreinamento = 0;
88
        try {
90        while (erro) {
            this.numEpocasTreinamento++;
92          acertou = 0;
            erro = false;
94          arq = new FileReader(arquivoTreinamento.getCaminhoCompleto());
            lerArq = new BufferedReader(arq);
96
            linha = lerArq.readLine();
98          if (linha.contains("x1")) {
              linha = lerArq.readLine();
100         }

102         while (linha != null) {
              vetor = linha.split("\\s+");
104           i = 0;

106           if (vetor[0].equals("")) {
                i = 1;
108           }

110           entrada1 = Double.parseDouble(vetor[i++].replace(",", "."));
              entrada2 = Double.parseDouble(vetor[i++].replace(",", "."));
112           entrada3 = Double.parseDouble(vetor[i++].replace(",", "."));
              saidaEsperada = Double.parseDouble(vetor[i].replace(",", ".")
114
              ultimaResposta = funcaoDegrauBipolar((entrada1 * this.peso1)
```

```
116                     + (entrada2 * this.peso2) + (entrada3 * this.peso3)
                            + (-1.0 * this.peso0));
118
            if (this.ultimaResposta != saidaEsperada) {
120             peso0 = peso0 + (PASSO_APRENDIZAGEM * (saidaEsperada
                                - this.ultimaResposta) * -1.0);
122             peso1 = peso1 + (PASSO_APRENDIZAGEM * (saidaEsperada
                                - this.ultimaResposta) * entrada1);
124             peso2 = peso2 + (PASSO_APRENDIZAGEM * (saidaEsperada
                                - this.ultimaResposta) * entrada2);
126             peso3 = peso3 + (PASSO_APRENDIZAGEM * (saidaEsperada
                                - this.ultimaResposta) * entrada3);
128             erro = true;
              } else {
130             acertou++;
              }
132
              linha = lerArq.readLine();
134         }

136         arq.close();

138         if (acertou > maiorAcerto) {
              maiorAcerto = acertou;
140           Comunicador.addLog("Epoca " + numEpocasTreinamento
                        + " acertou " + acertou + " (" + peso0 + "; "
142                         + peso1 + "; " + peso2 + "; " + peso3 + ")");
            }
144
          }
146
          Comunicador.addLog("Fim do treinamento.");
148     } catch (FileNotFoundException ex) {
          return false;
150     } catch (IOException ex) {
          return false;
152     }

154     return true;
```

```
    }
156
    public String classificar(double valor1, double valor2,
158   double valor3) {
      String resposta;
160
      resposta = "Sem classificacao";
162
      this.ultimaResposta = funcaoDegrauBipolar((valor1 * this.peso1)
164         + (valor2 * this.peso2) + (valor3 * this.peso3)
            + (-1.0 * this.peso0));
166
      if (this.ultimaResposta == -1.0) {
168     resposta = "Classe P1";
      }
170   if (this.ultimaResposta == 1.0) {
        resposta = "Classe P2";
172   }

174   return resposta;
    }
176
    private double funcaoDegrauBipolar(double valor) {
178   if (valor == 0.0) {
        return 0.0;
180   }

182   if (valor < 0.0) {
        return -1.0;
184   }

186   if (valor > 0.0) {
        return 1.0;
188   }

190   return 0.0;
    }
192
}
```

ANEXO A - CONJUNTO DE TREINAMENTO

x1	x2	x3	d
-0.6508	0.1097	4.0009	-1.0000
-1.4492	0.8896	4.4005	-1.0000
2.0850	0.6876	12.0710	-1.0000
0.2626	1.1476	7.7985	1.0000
0.6418	1.0234	7.0427	1.0000
0.2569	0.6730	8.3265	-1.0000
1.1155	0.6043	7.4446	1.0000
0.0914	0.3399	7.0677	-1.0000
0.0121	0.5256	4.6316	1.0000
-0.0429	0.4660	5.4323	1.0000
0.4340	0.6870	8.2287	-1.0000
0.2735	1.0287	7.1934	1.0000
0.4839	0.4851	7.4850	-1.0000
0.4089	-0.1267	5.5019	-1.0000
1.4391	0.1614	8.5843	-1.0000
-0.9115	-0.1973	2.1962	-1.0000
0.3654	1.0475	7.4858	1.0000
0.2144	0.7515	7.1699	1.0000
0.2013	1.0014	6.5489	1.0000
0.6483	0.2183	5.8991	1.0000
-0.1147	0.2242	7.2435	-1.0000
-0.7970	0.8795	3.8762	1.0000
-1.0625	0.6366	2.4707	1.0000
0.5307	0.1285	5.6883	1.0000
-1.2200	0.7777	1.7252	1.0000
0.3957	0.1076	5.6623	-1.0000
-0.1013	0.5989	7.1812	-1.0000
2.4482	0.9455	11.2095	1.0000
2.0149	0.6192	10.9263	-1.0000
0.2012	0.2611	5.4631	1.0000